# PLAYING ATARI WITH DEEP REINFORCEMENT LEARNING

박데이터융합학과 2021512018 박소미

# CONTENT


- Abstract
- Introduction
- Background
- Deep Reinforcement Learning
- Experiment
- Result
- Conclusion

### **ABSTRACT**

### 과연 딥러닝 기술을 강화학습에 적용해도 효과가 있을 것인가?




DeepMind's Deep Q-learning playing Atari Breakout



# INTRODUCTION

- Deep Q-learning: 강화학습 + 딥러닝
- 딥러닝을 적용하기 위해 해결해야 할 강화학습 데이터의 특징
  - 1. 희박하고 노이즈가 많으며 딜레이가 있는 신호로서 품질이 좋지 않은 데이터
  - 2. 높은 상관관계의 데이터
  - 3. agent가 새로운 action 취할 때마다 바뀌는 데이터의 분포

### BACKGROUND



Markov Decision Process (MDP)

- Agent는 action, state, reward의 시퀀스로 Environment와 상호작용 함
- Agent는 현재의 장면만을 관찰하기에 전체 상황 이해하기 힘듦

action의 sequence 관찰하여 학습해서 미래 보상을 극대화시키는 방식으로 action을 선택함 (MDP)

# BACKGROUND

#### Reward

$$R_t = \sum_{t'=t}^T r^{t'-t} r_{t'}$$

### **Action Value Function**

$$Q_{i+1}(s,a) = \mathbb{E}\left[r + \gamma Q_i(s',a') \mid s,a\right]$$


#### **Loss Function**

$$L_{i}(\theta_{i}) = \mathbb{E}_{s,a \sim \rho(\cdot)} \left[ \left( y_{i} - Q(s,a;\theta_{i}) \right)^{2} \right], \text{ where, } y_{i} = \mathbb{E}_{s' \sim \mathcal{E}} \left[ r + \gamma \max_{a'} Q(s',a';\theta_{i-1}) \mid s,a \right]$$

$$\nabla_{\theta_{i}} L_{i}(\theta_{i}) = \mathbb{E}_{s,a \sim \rho(\cdot);s' \sim \mathcal{E}} \left[ \left( r + \gamma \max_{a'} Q(s',a';\theta_{i-1}) - Q(s,a;\theta_{i}) \right) \nabla_{\theta_{i}} Q(s,a;\theta_{i}) \right]$$

# Deep Reinforcement Learning


Deep Q-Network Architecture: CNN + RL




output은 input state에 대한 개별 action 예측한 Q-value

# Deep Reinforcement Learning

**Experience Replay** 



데이터의 높은 상관관계를 극복하고 학습을 안정적으로 만듦



# Deep Reinforcement Learning

```
Algorithm 1 Deep Q-learning with Experience Replay
   Initialize replay memory \mathcal{D} to capacity N
   Initialize action-value function Q with random weights
  for episode = 1, M do
       Initialise sequence s_1 = \{x_1\} and preprocessed sequenced \phi_1 = \phi(s_1)
       for t = 1, T do
            With probability \epsilon select a random action a_t
            otherwise select a_t = \max_a Q^*(\phi(s_t), a; \theta)
            Execute action a_t in emulator and observe reward r_t and image x_{t+1}
            Set s_{t+1} = s_t, a_t, x_{t+1} and preprocess \phi_{t+1} = \phi(s_{t+1})
            Store transition (\phi_t, a_t, r_t, \phi_{t+1}) in \mathcal{D}
            Sample random minibatch of transitions (\phi_j, a_j, r_j, \phi_{j+1}) from \mathcal{D}
           Set y_j = \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \gamma \max_{a'} Q(\phi_{j+1}, a'; \theta) & \text{for non-terminal } \phi_{j+1} \end{cases}
            Perform a gradient descent step on (y_i - Q(\phi_i, a_i; \theta))^2 according to equation 3
       end for
```

end for

# Experiment



게임 실험 환경 조건은 모두 동일하게 세팅


# Result


### 1. DQN이 우수한 성적을 받고 있음을 확인 할 수 있다

	B. Rider	Breakout	Enduro	Pong	Q*bert	Seaquest	S. Invaders
Random	354	1.2	0	-20.4	157	110	179
Sarsa [3]	996	5.2	129	-19	614	665	271
Contingency [4]	1743	6	159	-17	960	723	268
DQN	4092	168	470	20	1952	1705	581
Human	7456	31	368	-3	18900	28010	3690
HNeat Best [8]	3616	52	106	19	1800	920	1720
HNeat Pixel [8]	1332	4	91	-16	1325	800	1145
DQN Best	5184	225	661	21	4500	1740	1075

### Result


### 2. Q Value값을 통해 반복이 거듭될 수록 학습이 잘 되는 것을 알 수 있다






# Result

3. 게임 화면을 통해서도 Q가 잘 작동하고 있음을 확인할 수 있다




# Conclusion

#### 의박하고 노이즈가 많으며 딜레이가 있는 신호 품질이 좋지 않은 데이터



CNN기반인 DQN 알고리즘으로 학습

#### 높은 상관관계의 데이터 불규칙한 데이터의 분포



**EXPERIENCE REPLAY**